

# 基于卷积神经网络的微博舆情情感分类研究

张海涛<sup>1,2</sup>, 王 丹<sup>1</sup>, 徐海玲<sup>1</sup>, 孙思阳<sup>1</sup>

(1. 吉林大学管理学院, 长春 130022; 2. 吉林大学信息资源研究中心, 长春 130022)

**摘 要** 本文基于卷积神经网络构建了微博舆情情感分类模型, 通过爬虫方式获取微博话题数据, 利用 word2vec 训练词向量, 采用 NLP/ICTCLAS2016 工具进行分词, 进而通过 Matlab 编程实现模型训练和测试。结果表明, 模型能够实现有效的微博舆情情感分类, 相较传统机器学习具有一定的优越性。

**关键词** 深度学习; 卷积神经网络; 微博舆情; 情感识别

## Sentiment Classification of Micro-blog Public Opinion Based on Convolution Neural Network

Zhang Haitao<sup>1,2</sup>, Wang Dan<sup>1</sup>, Xu Hailing<sup>1</sup> and Sun Siyang<sup>1</sup>

(1. Management School of Jilin University, Changchun 130022;  
2. The Information Resource Research Center of Jilin University, Changchun 130022)

**Abstract:** In this paper, a sentiment classification model of micro-blog public sentiment is constructed based on convolution neural network. Micro-blog topic data is obtained by crawling and using word2vec to train word vectors. NLP/ICTCLAS 2016 tools were used for word segmentation and subsequently MATLAB programming model training and testing. The results show that the model can achieve an effective sentiment classification of micro-blog public sentiment, which is superior to traditional machine learning.

**Key words:** deep learning; convolution neural network; micro-blog public opinion; emotion recognition

## 1 引 言

当今时代, 网络舆情的影响越来越大, 已经成为社会舆情的重要组成部分。网络舆情的产生和爆发离不开网民的交互以及提供交互的网络平台, 据《2017 年中国社交媒体影响报告》统计, 目前市场占有率最高的社交媒体主要有微信、QQ、微博、今日头条等, 这些社交媒体用户基数大、新闻热点多, 极易成为舆论场。与此同时, 微博较微信和 QQ 而言, 信息环境更开放, 热点实时更新等特点也不断刺激着舆情的产生。截至 2017 年 12 月, 微博月活

跃用户 3.92 亿, 日活跃用户也高达 1.72 亿, 微博已然成为网络舆情传播的主阵地之一。但由于微博用户在社会经验、信息素养和教育程度等方面存在较大差异, 同时受身份隐秘性影响, 代表偏激或者非理性观点的微博舆情信息更容易扩散。面对浩如烟海的微博信息, 如何识别其中蕴含的情感倾向, 由此洞察微博用户对社会热点事件的真实态度和观点, 进而对微博舆情有效监测、预警及疏导, 对微博舆情生态系统的良性发展具有重要意义。

众多学者针对网络舆情、微博舆情展开了深入的情感识别研究。Vermeulen 等<sup>[1]</sup>对社交媒体上青少

收稿日期: 2018-05-11; 修回日期: 2018-05-30

作者简介: 张海涛, 男, 1966 年生, 管理学博士, 教授, 博士生导师, 研究方向为情报学理论与方法、信息生态理论与应用、网络舆情, E-mail: zhtinfo@126.com; 王丹, 女, 1990 年生, 博士研究生, 研究方向网络舆情; 徐海玲, 女, 1989 年生, 博士研究生, 研究方向为网络舆情; 孙思阳, 女, 1990 年生, 博士研究生, 研究方向为信息生态理论与应用。

年的情感分享进行了深入分析; Sun 等<sup>[2]</sup>基于社交媒体的商业智能用户异常情绪检测; Mohammad 等<sup>[3]</sup>使用哈希标签从推特中捕获优秀情感类别; Yang 等<sup>[4]</sup>改进 Kim 模型, 基于卷积神经网络理论, 对 Twitter 推文进行了分类研究, 并验证了卷积神经网络对 Twitter 信息情感分类的优越性能; 国内学者吴青林等<sup>[5]</sup>基于灰色跟踪理论构建了微博情感识别模型, 利用模型对微博信息进行聚类及情感强度分析, 进而跟踪微博用户情感变化, 并通过实验验证了模型及分析方法的有效性和可行性; 周瑛等<sup>[6]</sup>引入深度学习理论, 提出了基于注意力机制的 LSTM 模型, 以微博评论数据为样本, 对微博热点事件用户的情感趋向展开研究, 实验结果表明, 模型在长文本微博信息的情感特征分析上较为有效; 蔡瑶等<sup>[7]</sup>基于 ACT-R 理论, 结合网民负面情感决策目标, 提出微博情感认知决策模型, 并以“天津爆炸”时间为例对模型进行验证, 实验结果反映了微博用户负面情感产生过程, 为微博舆情情感疏导提供了指引。此外, 王英等<sup>[8]</sup>以“南昌大学自主保洁”微博舆情事件为例, 基于情感维度分析了网民情感倾向; 陈娟等<sup>[9]</sup>对政府辟谣信息用户评论情感倾向进行了研究; 梁晓敏等<sup>[10]</sup>对舆情事件中评论对象的情感展开了分析。

可见, 情感分类、识别领域理论研究基础较为深厚, 国内外学者在网络舆情、微博舆情情感分类、识别研究方面也取得了一定成果。然而, 虽然卷积神经网络在微博舆情情感分类领域的应用具有一定的可行性, 但较少有学者构建基于卷积神经网络的微博舆情情感分类模型, 并通过实验方式验证模型的有效性, 并对情感分类准确性和效率进行对比分析。由此, 本文确立了以下 3 个方面的主要研究问题: ①如何基于卷积神经网络构建微博舆情情感分类模型? ②怎样通过实验的方法对模型进行验证? ③所构建的模型在微博舆情情感分类领域的先进性如何?

## 2 相关理论

### 2.1 情感识别及分类








情感是人类对现实世界的内部主观体验和特殊的反映形式, 因而, 情感识别涉及计算科学、心理学、认知科学等交叉学科领域。其概念可以定义为, 通过对人类面部表情、身体姿势、信息行为的研究, 掌握人类情绪变化的规律性, 从而辨识人类在不同情境下的情感倾向的过程<sup>[11]</sup>。情感识别的实践应用

较为广泛, 例如, 可以应用于服务行业的电话呼叫中心、教育行业的远程教学、医学领域的孤僻症患者康复、娱乐业方面的游戏动漫, 当然, 也可用于微博舆情监测、引导和治理<sup>[12]</sup>。

情感分类旨在解决情感极性的判断问题, 是情感识别和情感分析的重要基础。然而, 基于人类情感复杂多变的现实, 目前并没有公认的情感划分标准。Ekman<sup>[13]</sup>通过对人类面部所表达情感的研究, 将人类情感划分为高兴、愤怒、恐惧、厌恶、惊讶、悲伤等六个类别。Quan 等<sup>[14]</sup>将网民在博客中的情感划分为期待、讨厌、喜爱、高兴、焦虑、惊讶、悲伤、生气等 8 大类。Ortony 等<sup>[15]</sup>最早提出了认知情感评价 OCC 模型, 通过分类、量化、映射、表达四个认知过程衡量信息接受者情绪, OCC 模型可有效应用于 Twitter 情感识别研究。徐琳宏<sup>[16]</sup>则结合中国七情六欲的传统理念, 将情感分为乐、怒、哀、好、恶、惧、惊 7 类。

本文根据研究需要, 结合微博用户对微博信息的转发、评论、点赞行为, 将微博用户的情感划分为高兴、赞赏、惊讶、悲伤、厌恶、恐惧、愤怒等 7 类, 上述分类同我国传统的“七情”分类较为一致, 情感分类及典型微博内容表情符、例词如表 1 所示。

表 1 微博情感分类

情感分类	典型表情符	典型例词
高兴		欢天喜地、眉欢眼笑、大喜过望、笑逐颜开
赞赏		交口称赞、有口皆碑、孜孜不倦 兢兢业业
惊讶		瞠目结舌、目瞪口呆、大吃一惊、大惊失色
悲伤		泣不成声、吞声忍泪、悲不自胜、悲痛欲绝
厌恶		讨厌、厌恶、恶心、憎恶、 厌憎、反感
恐惧		惶恐不安、不寒而栗、心有余悸、胆战心惊
愤怒		怒发冲冠、怒不可遏、冲冠眦裂、暴跳如雷

### 2.2 卷积神经网络

卷积神经网络 (convolutional neural networks, CNN) 是深度学习领域的重要分支, 是根据生物学上感受野机制提出的一种前馈神经网络<sup>[17]</sup>。典型的卷积神经网络包括输入层、卷积层、池化层和全连接层四种层次结构<sup>[18]</sup>, 如图 1 所示。

CNN 首先基于已知样本标签的训练集数据对模




图1 卷积神经网络模型

型进行训练,由此达到自动深入学习输入数据特征的目标,当输入没有标签的新数据后,训练好的模型可以自动计算新数据的标签<sup>[19]</sup>。也就是说,在情感分类领域的应用中,训练集的每一条微博信息情感极性已知,基于微博信息及情感极性标签对模型进行训练,达到训练精度要求,则输入新的微博信息数据,输出对应微博信息数据的情感极性标签,进而达到微博信息情感分类目标<sup>[20]</sup>。Kim<sup>[21]</sup>在美国有线电视新闻网开展的卷积神经网络实验基础上,对卷积神经网络模型进行了架构优化,由此可通过微调学习任务向量提高情感分析及分类性能,并进而证实了卷积神经网络在语义分析、话题分类等Twitter信息处理任务中,具有较好的效果;蔡国永等<sup>[22]</sup>利用卷积神经网络对图文融合媒体进行了情感预测。

在情感分类的理论和实践研究中,聚类技术、文本关键词提取、语义理解和机器学习等技术被不断采用,并取得了一定的研究成果<sup>[23]</sup>。如前文所述,

基于情感词典是传统情感分析的基础,但往往情感词典的建设成本较高、覆盖面不够广泛、更新难度大、准确性低。因而,学者纷纷采用机器学习和人工智能技术以弥补传统研究的不足,而卷积神经网络具有强大的特征学习能力,能够克服人工特征抽取的困难,从而使得情感分类和学习更容易、更可行,可以大大提高情感分类的效率和识别准确性,逐渐得到专家学者的青睐,并在实践层面得以广泛应用<sup>[24]</sup>。

### 3 基于卷积神经网络的微博舆情情感分类模型构建

基于国内外相关学者的研究成果,本文构建了基于卷积神经网络的微博舆情情感分类模型,如图2所示。模型共包括微博数据采集、数据清洗及预处理、CNN模型训练及测试、情感分类及结果分析等四个部分。数据采集可以采用爬虫或API接入微博开放平台的方式获取。数据清洗及预处理主要对无效字段、垃圾信息等数据进行处理,排除对分类效果产生较大干扰的数据。训练集和测试集的情感分类采用人工标注的形式,训练集合的数据量要相对较大,以提高分类准确率。模型训练达到精度要求后,则应用于待分类数据集进行情感分类,最后对分类结果进行讨论分析。下面重点对数据采集和预处理、CNN微博舆情情感分类模型算法进行阐述。

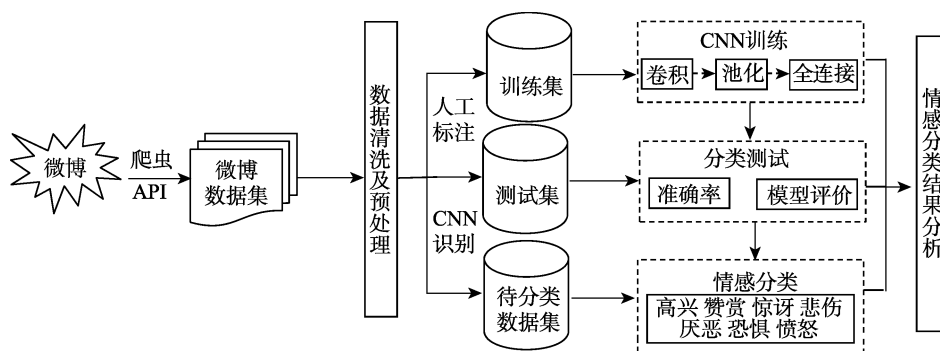


图2 基于卷积神经网络的微博舆情情感分类模型

#### 3.1 数据采集和预处理

数据主要来源于微博网站或微博wap站,网址分别为weibo.com、m.weibo.cn。按照话题、分类或者搜索选择目标微博,采取蜘蛛爬虫或者编程的方式接入API微博开放平台,获取微博博文或者评论数据。其中,蜘蛛爬虫优势在于可以并发线程获取

数据,完全模拟浏览器访问,设置简单规则后,不需要人工值守即自动获取数据,数据获取的技术门槛较低。但存在大样本数据量获取效率稍低、不能突破微博的后台数据访问限制等缺点,对于几十万规模以下的微博数据获取可以采用此方式。编程接入API方式,虽然效率较高,但是需要得到相应的微博授权才能获取大量的微博信息,并且具有一定

的技术门槛。

获取一定量的数据后,则需要进行数据清洗和预处理。数据清洗主要对字段缺失值、乱码信息、大量重复信息进行处理,形成有效的初始数据集。然后进行数据预处理,数据预处理的主要目的,是形成用于CNN模型训练、测试及分类的训练数据集、测试数据集,以及待分类的数据集。需要说明的是,理论上讲,训练集的数量越多,则分类的结果越准确。然而,在实践中,必须考虑情感分类成本和效率。因而,训练集合的确定是一个渐进的过程,达不到测试精度,则需要扩充训练集,直至测试精度达到目标要求为止。在情感分类训练集合测试集的确定过程中,需要采取人工的形式,对每一条微博或微博评论,进行情感极性分类,建立人工情感极性字段并输入数据。

### 3.2 CNN 微博舆情情感分类模型算法

CNN 微博舆情情感分类模型算法的主要原理是,利用大量已经人工标注情感极性的微博博文或评论数据训练集对模型进行训练,将训练好的模型输入测试集数据展开测试,达到精度要求后,则对待分类微博进行情感分类,相较语义词典等情感分类模型,具有分类精度高、噪声数据分析能力强的优点。

CNN 微博舆情情感分类模型训练算法包括4步2个阶段。第一阶段是向前传播阶段,首先从训练集 $(\text{train\_}x^i, \text{train\_}y^k)$ 中抽取一个样本 $\text{train\_}x$ 输入网络,计算实际的输出值 $\text{opts\_}y^k$ ,在这一阶段,信息从输入层到输出层逐级变换,并执行公式(1)运算。第二阶段是向后传播阶段,首先计算实际输出 $\text{opts\_}y^k$ 和目标输出 $\text{train\_}y^k$ 的差,接着按照精度控制要求调整矩阵。其中第一、第二阶段的计算必须在样本误差范围内,样本集误差 $rL = \sum rL^k$ ,第 $k$ 个样本的误差 $rL^k$ 按照公式(2)进行测度。

$\text{opts\_}y^k = F_n(\cdots(F_2(F_1(\text{train\_}x^i W(1)) W(2)) \cdots) W(n))$  (1)

$$rL^k = \frac{1}{2} \sum_{j=1}^n (\text{train\_}y_j^k - \text{opts\_}y_j^k)^2 \quad (2)$$

从微博舆情信息的传播方向来看,第二阶段的求解过程同微博对于微博舆情信息的链式传播路径方向相反,在神经元连接权重调整时,输出层误差能够被求解,然而其他层误差则需要基于误差反向逐层推演才能得出,因而第二阶段也称为向后传播阶段或误差传播阶段。在训练过程中,设输入层单

元数为 $N$ 、中间层单元数为 $Z$ 、输出层单元数为 $C$ ,输入向量 $X=(x_0, x_1, \cdots, x_n)$ ,中间层输出向量 $M=(m_0, m_1, \cdots, m_z)$ ,输出层向量 $Y=(y_1, y_2, \cdots, y_c)$ ,目标输出向量 $O=(o_1, o_2, \cdots, o_c)$ ,输出单元和隐含单元的权重是 $V_{ij}$ ,隐含单元到输出单元的权重是 $W_{jk}$ ,隐含单元阈值 $\partial_j$ ,输出单元阈值。

则中间层、输出层算法分别如公式(3)、公式(4)所示,其中 $f^*$ 。

$$m_j = f \left( \sum_{i=0}^{n-1} v_{ij} x_i + \partial_j \right) \quad (3)$$

$$y_k = f \left( \sum_{j=0}^{z-1} w_{jk} m_j + \partial_k \right) \quad (4)$$

基于上述条件,微博舆情情感分类网络训练过程如下:

(1) 确定训练样本。从训练集中随机选择一定数量的微博舆情数据作为训练样本 $X$ 。

(2) 设定权重 $V_{ij}$ 、 $W_{jk}$ 以及阈值 $\partial_j$ 、为接近为0的随机数,初始化学习率 $\alpha$ 和误差控制参数 $\beta$ 。

(3) 从训练样本 $X$ 中选取一个样本 $x_i$ ,给定目标输出向量 $O$ 。

(4) 基于公式(3)算法求解中间层输出向量 $M$ ,再基于公式(4)算法求解实际输出向量 $Y$ 。

(5) 通过输出向量 $y_k$ 和目标向量 $O_k$ 比较计算输出误差 $\tau_k$ ,同理计算隐含层单元误差 $\tau_j$ 。其中,

$$\tau_k = (O_k - y_k) y_k (1 - y_k), \quad \tau_j = m_j (1 - m_j) \sum_{k=0}^{c-1} \tau_k W_{jk}.$$

(6) 按照公式(5)、公式(6)计算权重调整量,按照公式(7)、公式(8)计算阈值调整量。

$$\Delta V_{ij}(n) = (\alpha / (1+N)) \times (\Delta V_{ij}(n-1) + 1) \times \tau_j \times m_j \quad (5)$$

$$\Delta W_{jk}(m) = (\alpha / (1+M)) \times (\Delta W_{jk}(m-1) + 1) \times \tau_k \times m_j \quad (6)$$

$$\Delta \partial_k(n) = (\alpha / (1+N)) \times (\Delta \partial_k(n-1) + 1) \times \tau_j \quad (7)$$

$$\Delta \partial_j(m) = (\alpha / (1+N)) \times (\Delta \partial_j(m-1) + 1) \times \tau_j \quad (8)$$

(7) 当 $k$ 遍历1到 $C$ 后,若样本集误差 $rL$ 小于等于误差控制参数 $\beta$ ,则进入下一步,否则返回步骤(3)迭代计算至满足条件为止。

(8) 保存权重和阈值数据,分类器训练完成。

## 4 实证研究

为验证本文提出的模型,并进行对比性实验,本文选择虚拟机实验环境,并选择了主流工具完成实验。在实验过程中,首先在服务器虚拟机中安装

爬虫工具, 设定数据采集规则, 获取数据保存到 MySQL 数据库, 对数据进行清洗和处理后, 利用 Matlab 编程工具, 在深度学习工具包基础上编写程序, 实现对模型的训练和测试。针对测试结果, 采用传统的 SVM 工具包, 基于情感词典对数据进行分词并完成了情感分类。进而针对实验结果进行讨论和对比性分析。

#### 4.1 实验环境

实验在服务器上的虚拟机进行, 操作系统为 LinuxCentOS, 数据库采用 MySQLVer 14.14, 爬虫工具为 LocoySpider v9, 分词工具为 NLPIR/ICTCLAS2016, 词向量训练工具为 GOOGLE Word2vec, 编程工具利用 Matlab R2010 a, 并借助了相关工具包, 详见表 2。

表 2 实验环境及配置

试验环境	环境配置
操作系统	LinuxCentOS
CPU	Xeon E5-2603 v3
内存	DDR4 8GB
带宽	独享 2Mbps
数据库	MySQLVer 14.14
爬虫工具	LocoySpider v9
分词工具	NLPIR/ICTCLAS2016
词向量训练工具	word2vec
编程工具	Matlab R2010 a
深度学习工具包	DeepLearnToolbox (author: Palm RB)
SVM 工具包	LIBSVM (作者: 台湾大学林智仁)

#### 4.2 实验数据

本文通过 2018 年 4 月微博话题榜的有关话题及评论数据的分析, 结合百度指数、微博指数, 最终选择具有一定争议性的#打呼噜被室友群殴#话题为例。该话题阅读量 241.7 万、评论数 3399、话题粉丝 211 人。该话题原创微博数 161 条, 微博用户纷纷通过点赞、评论发表自己的观点, 对事件的争论较为激烈。截止 2018 年 4 月 25 日 13 时, 本文利用爬虫工具共采集数据 3560 条。进而随机抽取数据形成训练集、测试集、待分类数据集, 详见表 3。

表 3 数据集

类别	训练集	测试集	待分类数据集	数据总量
原创微博数据	75	31	75	161
评论数据	500	99	2800	3399
原创微博及评论数据	1200	160	2200	3560

#### 4.3 实验内容设计

为达到“验证基于卷积神经网络的微博舆情情感识别模型有效性、科学性、深度学习的优越性”等实验目的, 本文对试验内容和流程进行了如下设计:

(1) 微博舆情数据情感标注。对获取到的数据进行清洗和整理, 形成初步的数据集。进而招募在校大学生基于表 1 的分类区分标准, 统计微博内容中表情符和情感词数量, 然后按照“高兴、赞赏、惊讶、悲伤、厌恶、恐惧、愤怒”7 个类别进行情感极性初步标注。为了保证人工标注的信效度, 本文又组成了由情报学专家 1 名、博士研究生 2 名、硕士研究生 2 名的复核小组, 对情感极性标注进行复核并形成最终训练样本集。

(2) 词向量训练。将原创微博或评论数据作为词向量训练预料, 利用 word2vec 训练词向量, 得到词向量训练列表。同时, 将每一条原创微博及评论数据采用 NLPIR/ICTCLAS2016 工具进行分词, 用于对比实验需要采用的数据。

(3) 卷积神经网络情感识别模型编程。采用 Matlab R2010 a 工具, 利用 DeepLearnToolbox 工具包, 实现模型算法, 核心 *m* 文件伪代码如下:

```
weibo_CNN.m
function weibo_CNN;
load weibo_uint;
定义 train_x、test_x、train_y、test_y;
rand('state',0)
cnn.layers=input_layer、outputmaps、scale、
outputmaps、kernelsize、type
cnn = cnnsetup(cnn, train_x, train_y);
opts.alpha 赋值;
opts.batchsize 赋值;
opts.numepochs 赋值;
cnn = cnntrain(cnn, train_x, train_y, opts);
plot mean squared error
figure; plot(cnn.rL);
```

(4) 模型参数调节。为了不断提升模型情感识别性能, 对初始的词向量维度、Dropout、L2 等参数进行调节。

(5) 深度学习和机器学习效果对比。在机器学习领域, 一般认为支持向量机 SVM 情感分分类效果较好。因而, 为验证本文所构建模型的优越性, 仍然利用 Matlab 结合 LIBSVM 工具包对上述数据进行情感分类, 进而同深度学习的分类进行对比分析。



#### 4.4 讨论分析

##### 1) 模型训练及测试

词向量在模型训练效率及分类精度上具有重要作用,因而首先要利用相关工具,训练字、词级别的词向量。本文利用 word2vec 工具,设定出现次数 5 次以上的字形成字典。在词级别的词向量训练阶段,首先利用 NLP/ICTCLAS2016 进行分词,然后进行词向量训练,出现次数超过 5 次的加入字典。最终得到字级别词向量 3086 条,词级别词向量 11285 条。训练过程中的 word2vec 参数设置如表 4 所示。

表 4 word2vec 参数设置

参数	值	参数	值
sg	算法选择	1	min_count
size	特征向量维度	300	sample
iter	迭代次数	5	window
			字典截断
			5
			高频词阈值
			$1 \times 10^{-4}$
			窗口
			10

表 5 CNN 模型情感分类准确率

数据样本	1	2	3	4	5	6	7	8	9	10	平均值
原创微博	88.51	93.99	94.42	92.71	94.24	93.62	94.09	94.52	88.51	89.37	92.41
评论	94.56	88.93	91.24	92.39	88.57	88.45	95.98	96.57	89.23	87.54	91.35
所有数据	89.14	94.55	92.98	90.05	88.86	93.39	91.62	91.81	91.89	93.42	91.77

L2 参数从 0 到 0.9 变化对模型的影响如图 3 所示。由图 3 可见,参数的变化并未对模型产生具有规律性的明显影响,但情感分类准确率在 L2 取值 0.4 时准确率更高,因而可以推定 L2 参数在 0.4 附近取值时,对微博舆情情感识别分类的作用更积极。同时,从数据分类上来看,原创微博的情感分类准确率也大体高于其他两个分类。




图 3 L2 参数变化对模型的影响

Dropout 参数从 0.1 到 0.9 变化对模型的影响如图 4 所示。相较 L2 参数变化趋势,Dropout 参数变化对模型的影响呈现一定的规律性。当参数在 0.1 至

在确定了词向量后,需要在 CNN 模型训练前进行超参数配置。本文将卷积核尺寸配置为(4, 300),特征映射数量为 100, dropout 比率为 0.5, L2 正则化系数为 3。进而以#打呼噜被室友群殴#话题的原创微博数据、评论数据以及所有数据对模型进行了 10 次训练和测试,基于原创微博数据的情感分类准确率均值为 92.41%,基于评论数据的准确率均值为 91.35%,基于全部数据的情感分类准确率为 91.77%,分类准确率详细结果如表 5 所示。原创微博训练集的数量虽然较小,但是其情感分类准确率高于评论数据,并进而提高了所有数据的情感分类准确性。一方面说明本模型对于长文本的情感分类效果较好,而对短文本的情感分类效果有待提升。为进一步探究上述差异的原因,以及挖掘超参数的变化对模型的影响,本文分别调整 L2 参数、Dropout 参数、训练次数进行实验,下面予以分别阐述。

0.5 区间变化时,准确率较高,防止过拟合的效果最好。因而,在微博舆情情感分类模型的深度学习过程中,采用 Dropout 策略是非常有必要的。

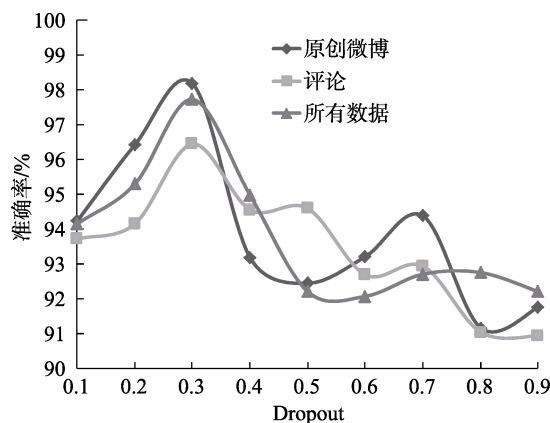


图 4 Dropout 参数变化对模型的影响

训练次数的增加对模型的影响如图 5 所示。随着训练次数的增加情感分类的误差率逐步下降。在训练次数增加的初级阶段,误差率下降较快,在中期阶段误差率下降速度开始减缓,当训练次数超过 1200 次以后,误差率反而有所提升,意味着并不是训练次数越多效果越好,要避免存在过度训练的情况出现。




图5 训练次数变化对模型的影响

## 2) 对比实验

为验证本文所构建模型的优越性，将 CNN 模型和 SVM 模型的微博舆情情感分类效果进行对比，结果如表 6 所示。同传统机器学习的主流模型 SVM 相比较，CNN 对微博舆情情感分类的准确率明显得到提高，三个类别数据的情感分类准确率分别提高了 8.09%、3.09%、2.63%。可见，本文所构建的基于卷积神经网络的微博舆情情感分类模型有效，相较传统机器学习方法，一定程度上具有较好的情感分类性能提升。并且，SVM 模型试验过程中，仅仅将情感划分为积极情感、中性情感、消极情感，而 CNN 模型则将情感按照“高兴、赞赏、惊讶、悲伤、厌恶、恐惧、愤怒”7 个类别进行识别，情感的识别细粒度更高。同时本文也注意到，SVM 模型对短文本的分类效果较好，而 CNN 则对原创微博等略长文本的分类效果较好，如何进一步提高 CNN 模型的短文本分类效果，有待在后续研究中进一步深入。

表 6 CNN 和 SVM 情感分类准确率对比 %

数据样本	SVM	CNN	提高率
原创微博	84.32	92.41	8.09
评论	88.26	91.35	3.09
所有数据	89.14	91.77	2.63

## 5 结 论

本文对微博舆情情感分类模型进行了研究，具有一定的理论研究价值和实践意义。在理论层面，构建了基于卷积神经网络的微博舆情情感分类模型，深化了卷积神经网络在微博舆情情感研究领域的应用，提高了情感分类准确率和效率。在实践层面，能够帮助微博管控主体准确识别微博舆情情感倾向，有利于舆情走势的精准研判，从而采取切实有效地措施进行舆论引导和控制，并为微博舆情生

态优化提供决策支持。

研究过程中，首先对国内外相关研究进行了梳理，厘清了情感分类及识别的概念，介绍了卷积神经网络的基本模型和原理。进而基于卷积神经网络理论构建了微博舆情情感分类模型，并对数据采集和预处理、CNN 微博舆情情感分类模型算法进行了阐述。为了对所构建模型的有效性和优越性进行验证，本文以新浪微博 wap 站为信息源，以#打招呼被室友群殴#话题为例，采用爬虫方式获取数据，按照“高兴、赞赏、惊讶、悲伤、厌恶、恐惧、愤怒”7 个类别进行人工情感极性标注，形成实验训练集、测试集以及待分类数据集。利用 word2vec 训练词向量、采用 NLP/ICTCLAS2016 工具进行分词，进而对模型进行训练、测试以及对比性分析。研究结果表明，模型能够实现有效的微博舆情情感分类，相较传统机器学习具有一定的优越性。并且，L2 参数在 0.4 附近取值时，对微博舆情情感识别分类的作用更积极；当 Dropout 参数在 0.1 至 0.5 区间变化时，准确率较高，防止过拟合的效果最好；模型训练次数能够有效降低误差率，但也要避免过度训练；相较于 SVM 模型，CNN 模型对情感的识别细粒度更高，分类效果也得到一定提升。

尽管本文创新性地将字词级情感分析方法和卷积神经网络理论应用于微博舆情情感分类领域，并消除了对情感词典的依赖，克服了人工抽取特征的困难，提高了情感分类准确率和分类效率。但仍然存在一定的不足，一方面在于样本量相对较小，可能导致研究偏差；另一方面在短文本的情感分类效果上还有待进一步提升。后续研究中，将考虑采用连续卷积神经网络对模型做进一步改进，并扩大样本量展开进一步实验。

## 参 考 文 献

- [1] Vermeulen A, Vandebosch H, Heirman W. #Smiling, #venting, or both? Adolescents' social sharing of emotions on social media[J]. Computers in Human Behavior, 2018, 84: 211-219.
- [2] Sun X, Zhang C, Li G Q, et al. Detecting users' anomalous emotion using social media for business intelligence[J]. Journal of Computational Science, 2018, 25: 193-200.
- [3] Mohammad S M, Kiritchenko S. Using hashtags to capture fine emotion categories from tweets[J]. Computational Intelligence, 2015, 31(2): 301-326.
- [4] Yang X, Macdonald C, Ounis I. Using word embeddings in Twitter election classification[J]. Information Retrieval Journal, 2018, 21(2-3): 183-207.

- [5] 吴青林, 周天宏. 基于话题聚类及情感强度的中文微博舆情分析[J]. 情报理论与实践, 2016, 39(1): 109-112.
- [6] 周琰, 刘越, 蔡俊. 基于注意力机制的微博情感分析[J]. 情报理论与实践, 2018, 41(3): 89-94.
- [7] 蔡瑶, 吴鹏, 王佳敏, 等. 基于 ACT-R 理论模型的微博网民负面情感认知决策过程研究[J]. 情报科学, 2018, 36(1): 135-140.
- [8] 王英, 龚花萍. 基于情感维度的大数据网络舆情情感倾向性分析研究——以“南昌大学自主保洁”微博舆情事件为例[J]. 情报科学, 2017, 35(4): 37-42.
- [9] 陈娟, 刘燕平, 邓胜利. 政府辟谣信息的用户评论及其情感倾向的影响因素研究[J]. 情报科学, 2017, 35(12): 61-65.
- [10] 梁晓敏, 徐健. 舆情事件中评论对象的情感分析及其关系网络研究[J]. 情报科学, 2018, 36(2): 37-42.
- [11] Carr A. Understanding emotion and emotionality in a process of change[J]. Journal of Organizational Change Management, 2017, 14(5): 421-436.
- [12] 张石清, 李乐民, 赵知劲. 人机交互中的语音情感识别研究进展[J]. 电路与系统学报, 2013, 18(2): 440-451.
- [13] Ekman P. Facial expression and emotion[J]. American Psychologist, 1993, 48(4): 384-92.
- [14] Quan C Q, Ren F J. Construction of a blog emotion corpus for Chinese emotional expression analysis[C]// Proceedings of the 2009 Conference on Empirical Methods in Natural Language Processing. Stroudsburg: Association for Computational Linguistics, 2009, 3: 1446-1454.
- [15] Ortony A, Clore G L, Collins A. The cognitive structure of emotions[J]. Contemporary Sociology, 1988, 18(6): 2147-2153.
- [16] 徐琳宏. 基于语义资源的文本情感计算[D]. 大连: 大连理工大学, 2007.
- [17] Chen Y H, Krishna T, Emer J S, et al. Eyeriss: An energy-efficient reconfigurable accelerator for deep convolutional neural networks[J]. IEEE Journal of Solid-State Circuits, 2017, 52(1): 127-138.
- [18] Lecun Y, Bottou L, Bengio Y, et al. Gradient-based learning applied to document recognition[J]. Proceedings of the IEEE, 1998, 86(11): 2278-2324.
- [19] 李枫林, 柯佳. 基于深度学习框架的实体关系抽取研究进展[J]. 情报科学, 2018, 36(3): 169-176.
- [20] 吴鹏, 刘恒旺, 沈思. 基于深度学习和 OCC 情感规则的网络舆情情感识别研究[J]. 情报学报, 2017, 36(9): 972-980.
- [21] Kim Y. Convolutional neural networks for sentence classification[C]// Proceedings of the 2014 Conference on Empirical Methods in Natural Language Processing. Stroudsburg: Association for Computational Linguistics, 2014: 1746-1751.
- [22] 蔡国永, 夏彬彬. 基于卷积神经网络的图文融合媒体情感预测[J]. 计算机应用, 2016, 36(2): 428-431, 477.
- [23] 李杰, 李欢. 基于深度学习的短文本评论产品特征提取及情感分类研究[J]. 情报理论与实践, 2018(2): 143-148.
- [24] Lecun Y, Bengio Y, Hinton G. Deep learning[J]. Nature, 2015, 521(7553): 436.

(责任编辑 车 尧)